eii-u1-01-22150580

March 1, 2025

[26]:
```
import pandas as pd
df = pd.read_csv('https://raw.githubusercontent.com/PaulinaAragon/ESTADISTICA/
 ↪refs/heads/main/data.csv')
df
```

[26]:
```
     Duration  Pulse  Maxpulse  Calories
0          60    110       130     409.1
1          60    117       145     479.0
2          60    103       135     340.0
3          45    109       175     282.4
4          45    117       148     406.0
..        ...    ...       ...       ...
164        60    105       140     290.8
165        60    110       145     300.0
166        60    115       145     310.2
167        75    120       150     320.4
168        75    125       150     330.4

[169 rows x 4 columns]
```

[46]:
```
# a) Establesca una variable dependiente ( Y ) y una variable independiente ( X␣
 ↪).

import pandas as pd
df = pd.read_csv('https://raw.githubusercontent.com/PaulinaAragon/ESTADISTICA/
 ↪refs/heads/main/data.csv')

# eliminar registros  cpn valores faltantes
df.dropna(inplace=True)

#variable independiente: Duration
#variable dependiente: Calories

y=df['Calories']
x=df['Duration']
```

```python
# b. Realiza un gráfico con la dispersión y la recta de regresión ajustada.
import matplotlib.pyplot as plt
plt.scatter(x, y, color = 'red')
plt.xlabel('Duration') # nombrar eje x
plt.ylabel('Calories') # nombrar eje y
ax = plt.gca()
ax.spines['top'].set_visible(False)
ax.spines['right'].set_visible(False)
# Recta de regresion ajustada.
import statsmodels.api as sm
X_constante = sm.add_constant(x)
modelo = sm.OLS(y, X_constante).fit()

b0, b1 = modelo.params
Fun = lambda X: b0 + b1 * X
Yc = Fun(x)

plt.plot(x, Yc, color = 'black', linestyle = '--')

# c. Calcula el coeficiente de correlación y el coeficiente de determinación e␣
 ↪interpreta los resultados.
from scipy.stats import pearsonr
r,_ = pearsonr(x, y)
print(f'coeficiente de correlacion: {r: 0.4f}\n')
print(f'coeficiente de determinacion: {r ** 2: 0.4f}\n')

# d. Obtenga un intervalo de confianza del 98% para la pendiente de la recta de
# regresión lineal

import statsmodels.api as sm
x_constante = sm.add_constant(x)
modelo = sm.OLS(y, x_constante).fit()
nivel_de_confianza = 0.98
intervalo_de_confianza = modelo.conf_int(alpha = 1 - nivel_de_confianza)
intervalo_de_confianza_b1 = intervalo_de_confianza.iloc[1]
print(f'intervalo de confianza para b1 de {nivel_de_confianza: 0.0%}')
print(f'{intervalo_de_confianza_b1[0]: 0.4f} < b1 <␣
 ↪{intervalo_de_confianza_b1[1]: 0.4f}')

# d. Respalda tu conclusión usando ANOVA

from statsmodels.formula.api import ols
modelo_anova = ols('y ~ x', data = df).fit()
tabla_anova = sm.stats.anova_lm(modelo_anova)
print(tabla_anova)

#e. Verifica los supuestos
```

```
residuales = modelo.resid
plt.figure()
plt.scatter(x, residuales, color = 'red')
plt.xlabel('Duration')
plt.ylabel('Residuales')
ax = plt.gca()
ax.spines['top'].set_visible(False)
ax.spines['right'].set_visible(False)
plt.axhline(y = 0, color = 'black', linestyle = '--')

from scipy.stats import shapiro
_, valor_p_sh = shapiro(residuales)
print(f' valor_p Test de shapiro: {valor_p_sh: 0.4f}\n')

from statsmodels.stats.api import het_breuschpagan
_, valor_p_bp, _, _ = het_breuschpagan(residuales, x_constante)
print(f'Valor_p de Breusch-Pagan: {valor_p_bp: 0.4f}\n')
```

```
coeficiente de correlacion:  0.9227

coeficiente de determinacion:  0.8514

intervalo de confianza para b1 de  98%
 5.2890 < b1 <  6.1729
             df        sum_sq       mean_sq           F        PR(>F)
x           1.0  9.847530e+06  9.847530e+06  928.219489  5.795220e-69
Residual  162.0  1.718667e+06  1.060905e+04         NaN           NaN
 valor_p Test de shapiro:  0.0000

Valor_p de Breusch-Pagan:  0.0000
```

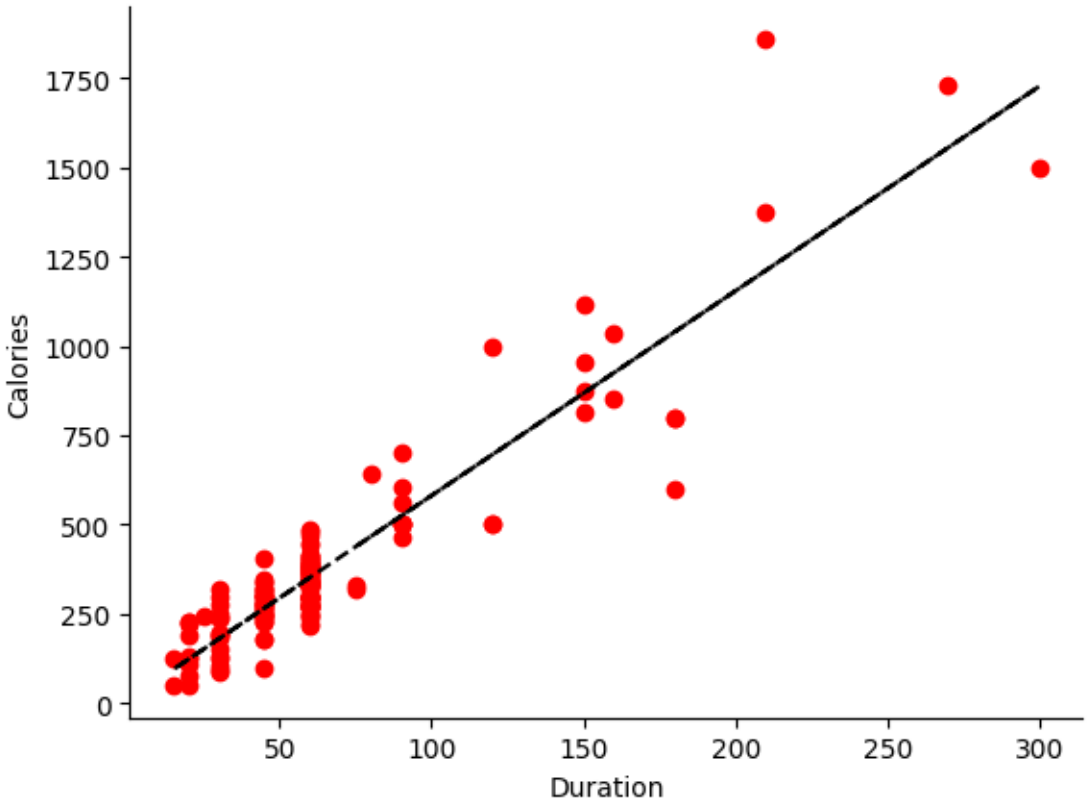
Calories
Duration
0
250
500
750
1000
1250
1500
1750
50
100
150
200
250
300

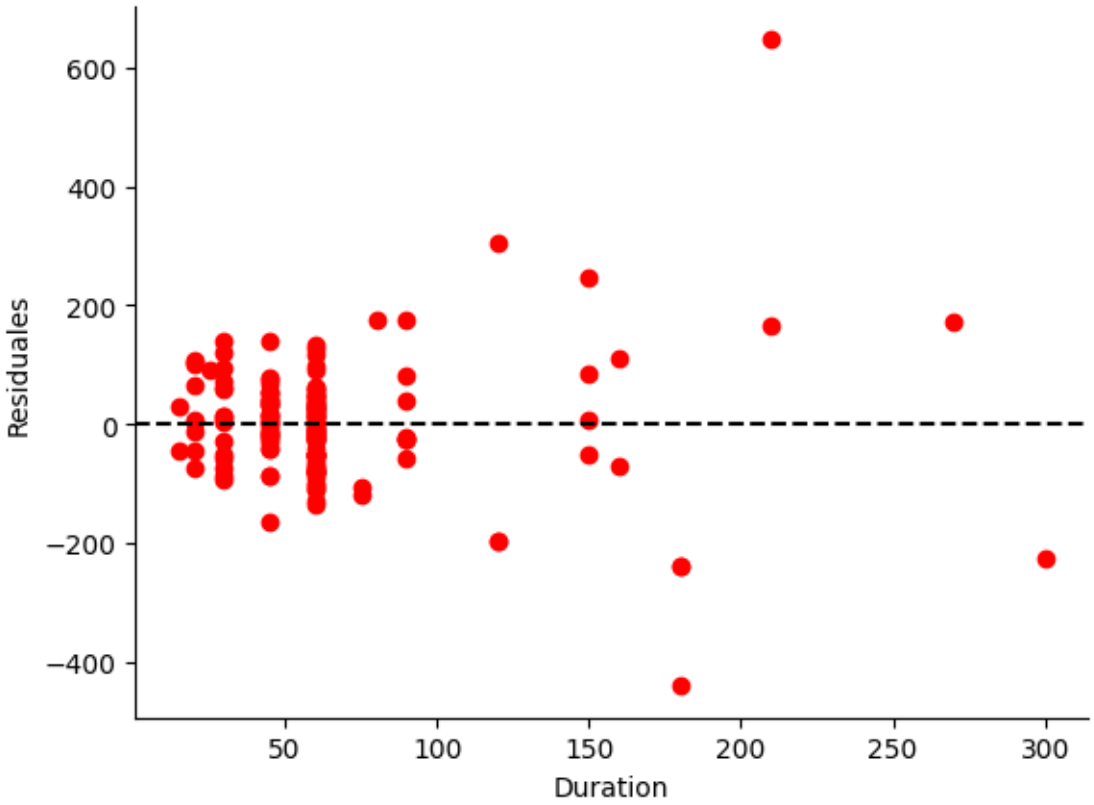
600
400
200
0
−200
−400
Residuales
50
100
150
200
250
300
Duration